

# 线性代数入门

梁鑫 田垠 杨一龙 编著

蔚 辉

清华大学丘成桐数学科学中心

报告中均非完整定义或准确表述。具体细节请参考教材。

## Definition

集合  $X$  到  $Y$  的映射

$$\begin{aligned} f: \quad X &\rightarrow Y, \\ x &\mapsto y = f(x). \end{aligned}$$

三种特殊情形:

- ① 单射: 零空间/核  $\mathcal{N}(f) = 0$ .
- ② 满射: 列空间/像集  $\mathcal{R}(f)$ .
- ③ 双射:  $f$  既是单射又是满射。

## Definition

集合  $X$  到  $Y$  的映射

$$\begin{aligned} f: \quad X &\rightarrow Y, \\ x &\mapsto y = f(x). \end{aligned}$$

三种特殊情形:

- ① 单射: 零空间/核  $\mathcal{N}(f) = 0$ .
- ② 满射: 列空间/像集  $\mathcal{R}(f)$ .
- ③ 双射:  $f$  既是单射又是满射。

- $X = Y$ : 变换。
- 映射的复合:  $g \circ f(x) = g(f(x))$ 。
- 逆映射:  $f^{-1}f(x) = x \quad \forall x \in X$ 。

- 1 数域  $\mathbb{F} \subset \mathbb{C}$ .
- 2 八条运算法则。
- 3 子空间：对加法和数乘封闭。
- 4  $\mathcal{R}(A) \perp \mathcal{N}(A^T)$ ,  $\mathcal{N}(A) = \mathcal{N}(A^T A)$  及其衍生等式。
- 5  $\mathcal{M}_1 \cap \mathcal{M}_2$ ,  $\mathcal{M}_1 + \mathcal{M}_2$ ,  $\mathcal{M}_1 \oplus \mathcal{M}_2$ .

设  $\mathbf{e}_1, \dots, \mathbf{e}_n$  和  $\mathbf{t}_1, \dots, \mathbf{t}_n$  分别是  $n$  维线性空间  $\mathcal{U}$  的一组基。应有

$$(\mathbf{t}_1, \dots, \mathbf{t}_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n)T.$$

其中  $T \in \mathbb{F}^{m \times n}$  是过渡矩阵，必定可逆。

- 基变换，坐标系变换，变量代换。
- 转化为一组标准正交基。

给定数域  $\mathbb{F}$  上的线性空间  $\mathcal{U}$  和  $\mathcal{V}$ . 考虑从  $\mathcal{U}$  到  $\mathcal{V}$  的映射  $f$ .

## Definition

称  $f$  为从  $\mathcal{U}$  到  $\mathcal{V}$  的线性映射, 如果线性运算满足可加性和齐次性:

- ❶ 任取  $\mathbf{x}, \mathbf{x}' \in \mathcal{U}$ , 有  $f(\mathbf{x} + \mathbf{x}') = f(\mathbf{x}) + f(\mathbf{x}')$ ;
- ❷ 任取  $\mathbf{x} \in \mathcal{U}, k \in \mathbb{F}$ , 有  $f(k\mathbf{x}) = kf(\mathbf{x})$ ,

► 表示矩阵与线性映射一一对应。

设  $\mathbf{e}_1, \dots, \mathbf{e}_n$  和  $\mathbf{i}_1, \dots, \mathbf{i}_m$  分别是  $n$  维线性空间  $\mathcal{U}$  和  $m$  维线性空间  $\mathcal{V}$  的一组基。

$$\mathbf{x} = x_1\mathbf{e}_1 + \dots + x_n\mathbf{e}_n = (\mathbf{e}_1, \dots, \mathbf{e}_n)\vec{x}.$$

$$f(\mathbf{x}) = \left(f(\mathbf{e}_1), \cdots, f(\mathbf{e}_n)\right) \vec{x} = \left(\mathbf{i}_1, \cdots, \mathbf{i}_m\right) F \vec{x},$$

其中表示矩阵为  $F \in \mathbb{F}^{m \times n}$ .

- 抽象线性映射  $f$  的核、像集、特征对等问题可以转化为表示矩阵  $F$  的对应问题。

取  $\mathbb{R}^n$  和  $\mathbb{R}^m$  的标准基, 有  $\mathbb{R}^n$  到  $\mathbb{R}^m$  的线性映射  $f$ :

$$f(\mathbf{x}) = A\mathbf{x},$$

其中  $A = [\mathbf{a}_1, \dots, \mathbf{a}_n] \in \mathbb{R}^{m \times n}$ , 且  $f(\mathbf{e}_i) = \mathbf{a}_i, \quad 1 \leq i \leq n$ .

- 初等矩阵：对换  $P_{ij}$ ，倍乘  $E_{ii;k}$ ，倍加  $E_{ji;k}$ 。
- 初等变换不改变矩阵的秩。
- 倍加变换不改变矩阵的行列式函数值。
- 任何矩阵都可通过初等行变换化为阶梯形或唯一的行简化阶梯形。
- 使用阶梯形或行简化阶梯形求解线性方程组和进行基扩充。
- 分块矩阵的设计和使用：分块初等矩阵。



## Definition

任意  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ :

$$\mathbf{x}^T \mathbf{y} = \sum_{i=1}^N x_i y_i.$$

- ▶ 向量长度  $\|\mathbf{x}\| = (\mathbf{x}^T \mathbf{x})^{\frac{1}{2}} = \left( \sum_{i=1}^N x_i^2 \right)^{\frac{1}{2}}.$
- ▶  $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}_n.$
- ▶ 非零向量  $\mathbf{x}, \mathbf{y}$  正交:  $\mathbf{x}^T \mathbf{y} = 0.$

- ①  $\mathbb{R}^m$  的标准基:  $\mathbf{e}_1, \dots, \mathbf{e}_m$ .
- ② 一组基  $\mathbf{a}_1, \dots, \mathbf{a}_s \rightarrow$  Gram-Schmidt 正交化  
 $\rightarrow$  一组标准正交基  $\mathbf{q}_1, \dots, \mathbf{q}_s$ .

$$[\mathbf{a}_1 \cdots \mathbf{a}_s] = [\mathbf{q}_1 \cdots \mathbf{q}_s][\mathbf{r}_1 \cdots \mathbf{r}_s] = [\mathbf{q}_1 \cdots \mathbf{q}_s] \begin{bmatrix} r_{11} & \cdots & r_{1s} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & r_{ss} \end{bmatrix}$$

按列对应相等:

$$\begin{aligned} \mathbf{a}_1 &= r_{11}\mathbf{q}_1, \\ \mathbf{a}_2 &= r_{12}\mathbf{q}_1 + r_{22}\mathbf{q}_2, \\ &\dots \end{aligned}$$

利用  $\mathbf{q}_i$  的正交性和单位化, 依次求解  $\mathbf{r}_i$  和  $\mathbf{q}_i$ .

- ③ 列不满秩情形下的Gram-Schmidt 正交化。

- ❶  $Q \in \mathbb{R}^{m \times m} : Q^T Q = I_m.$
- ❷ 保距:  $\|Q\mathbf{x}\| = \|\mathbf{x}\| \quad \forall \mathbf{x} \in \mathbb{R}^m.$
- ❸ 保内积:  $(Q\mathbf{x})^T (Q\mathbf{y}) = \mathbf{x}^T \mathbf{y}.$
- ❹ 旋转变换  $R_\theta$  和反射变换  $H_{\mathbf{v}} = I_m - 2\mathbf{v}\mathbf{v}^T$  with  $\|\mathbf{v}\| = 1$ 。
- ❺ 列正交矩阵  $Q_1$ , 扩充出  $Q_2$ , 得到正交矩阵  $Q$ , i.e., 子空间的一组标准正交基扩充成全空间  $\mathbb{R}^m$  的一组标准正交基。

- $P_{\mathcal{M}}$ : 投影到子空间  $\mathcal{M}$  的正交投影线性变换, 或正交投影矩阵。
- $P_{\mathcal{M}}^2 = P_{\mathcal{M}}^T = P_{\mathcal{M}}$ .
- $\forall \mathbf{a} \in \mathbb{R}^m$ , 有唯一分解:

$$\mathbf{a} = \mathbf{a}_1 + \mathbf{a}_2 \quad \text{with } \mathbf{a}_1 = P_{\mathcal{M}}\mathbf{a} \in \mathcal{M}, \quad \mathbf{a}_2 \in \mathcal{M}^{\perp}.$$

- $\mathcal{M} = \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_r)$ , 则有  $P_{\mathcal{M}} = Q_r Q_r^T$ ,

$$\mathbf{a}_1 = P_{\mathcal{M}}\mathbf{a} = Q_r Q_r^T \mathbf{a} = \sum_{j=1}^r (\mathbf{q}_j^T \mathbf{a}) \mathbf{q}_j.$$

- $\mathbf{a}$  到子空间  $\mathcal{M}$  的最短距离:

$$\|\mathbf{a} - P_{\mathcal{M}}\mathbf{a}\| = \min_{\tilde{\mathbf{a}} \in \mathcal{M}} \|\mathbf{a} - \tilde{\mathbf{a}}\|.$$

## Definition

$$\delta(\mathbf{a}_1, \dots, \mathbf{a}_n) = \delta(A) = \det(A) = |A|.$$

① 多线性:

$$\delta(\dots, k\mathbf{a}_i + k'\mathbf{a}'_i, \dots) = k\delta(\dots, \mathbf{a}_i, \dots) + k'\delta(\dots, \mathbf{a}'_i, \dots).$$

② 列反对称性:  $\delta(\dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots) = \delta(\dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots)$

③ 单位化条件:  $\delta(I_n) = 1$ .

- 倍加变换不改变行列式。
- 上（下）三角（分块）矩阵的行列式。
- $A$  可逆。  $\iff \det(A) \neq 0$ .

- $\det(A) = a_{1j}C_{1j} + \cdots + a_{nj}C_{nj}$ .
- $\mathbf{a}_i^T \mathbf{c}_j = \begin{cases} \det(A) & \text{if } i = j, \\ 0 & \text{if } i \neq j, \end{cases}$  with  $\mathbf{c}_j = [C_{1j} \cdots C_{nj}]^T$ .
- $A^{-1} = \frac{C^T}{\det(A)}$ , 其中伴随矩阵  $C^T = [\mathbf{c}_1 \cdots \mathbf{c}_n]^T$ .
- Cramer 法则.  $A\mathbf{x} = \mathbf{b}$  的解若存在, 则有

$$x_i = \frac{\det(B_i)}{\det(A)} \text{ for } i = 1, \dots, n.$$

$A\mathbf{x} = \lambda\mathbf{x} \iff (\lambda I_n - A)\mathbf{x} = \mathbf{0}$  有非零解。

❶  $\lambda$  是特征多项式

$$p_A(\lambda) = \det(\lambda I_n - A) = \lambda^n - \text{trace}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A)$$

的  $n$  个复根。

❷ Hamilton-Cayley 定理:  $p_A(A) = O$ .

❸  $\mathbf{x}$  是特征子空间  $\mathcal{N}(\lambda I_n - A)$  中的任意非零向量。

❹ 不同特征值对应的特征向量线性无关。

❺ 特征值的代数重数和几何重数。

❻ 单特征值, 半单特征值和亏损特征值。

### Definition

$\exists \sigma \in \mathbb{R}$ , 和非零向量  $\mathbf{x} \in \mathbb{R}^n, \mathbf{y} \in \mathbb{R}^m$ , s.t.

$$A\mathbf{x} = \sigma\mathbf{y}, \quad A^T\mathbf{y} = \sigma\mathbf{x}.$$

$A$  有  $r = \text{rank}(A)$  个正奇异值, 从大到小排序, 和  $AA^T$  或  $A^TA$  的  $r$  个正特征值一一对应:

$$\sigma_i = \sqrt{\lambda_i(AA^T)} = \sqrt{\lambda_i(A^TA)} \quad \text{for } i = 1, \dots, r.$$



- ①  $n$  阶实矩阵  $A$  正定:  $\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \text{ 非零 } \mathbf{x} \in \mathbb{R}^n$ .
- ② 实对称矩阵  $A$  正定的等价结论:
  - $\lambda_i(A) > 0$  for  $i = 1, \dots, n$ .
  - $\exists$  可逆  $T$ , s.t.  $A = TT^T$ .
  - $A = LDL^T$ , 其中对角矩阵  $D$  的对角元素都  $> 0$ ,  $L$  为单位下三角矩阵.
  - 顺序主子式都为正。
  - 顺序主子阵都正定。
- ③ 实对称矩阵的Cholesky 分解:  $A = LL^T$ , 其中  $L$  为下三角矩阵。
- ④  $A$  半正定的等价结论。

$A \in \mathbb{R}^{m \times n}$  with  $m \geq n$ , 存在 QR 分解:

$$A = QR = [Q_1 \quad Q_2] \begin{bmatrix} R_1 \\ O \end{bmatrix} = Q_1 R_1.$$

其中  $Q_1$  是  $m \times n$  列正交矩阵,  $R_1$  是  $n$  阶对角元素非负的上三角矩阵。  
当  $A$  可逆时,  $R_1$  的对角元素可全部取为正。

- 1 Gram-Schmidt 正交化:  $A = Q_1 R_1$  with  $\text{rank}(A) \leq n$ .
- 2 扩充出  $Q_2$ .
- 3 补足零元素, 由  $R_1$  得到  $R$ .
- 4  $\text{rank}(A) = r$ : 得到列空间  $\mathcal{R}(A)$  的一组标准正交基  $Q_r$ , 用于计算正交投影矩阵  $P_A = Q_r Q_r^T$ .

- 1  $A \in \mathbb{C}^{n \times n}$  可对角化:  $\exists$  可逆  $X$  和对角  $\Lambda$ , s.t.  $A$  有谱分解  $A = X\Lambda X^{-1}$ .
- 2  $\Lambda$ :  $n$  个特征值。  $X$ : 对应的  $n$  个线性无关的特征向量。
- 3  $A$  可对角化。  $\iff A$  的特征值都半单。
- 4 实对称矩阵的特征值都是实且半单。互异特征值对应的特征向量正交。
- 5 实对称矩阵总是有谱分解:  $A = Q\Lambda Q^T$ , 其中  $Q$  正交。

$$\textcircled{1} \quad A = U\Sigma V^T = U_r \Sigma_r V_r^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

► 实对称矩阵的谱分解:  $A^T A = V \Lambda V^T$  或  $AA^T = U \Lambda U^T$ .

► 得到  $\Sigma$  和  $V = [V_r \ V_2]$

►  $U_r = AV_r^T \Sigma_r^{-1}$ .

► 扩充出  $U_2$ , 得到  $U = [U_r \ U_2]$ .

$\textcircled{2}$  四个子空间  $\mathcal{R}(A), \mathcal{N}(A), \mathcal{R}(A^T), \mathcal{N}(A^T)$  与  $U$  和  $V$  的关联。

$\textcircled{3}$  Moore-Penrose 广义逆:  $A^+ = V_r \Sigma_r^{-1} U_r^T$ .

- 取  $\mathcal{M} = \mathcal{R}(A)$ , 记  $P_A$  为投影到列空间  $\mathcal{R}(A)$  的正交投影矩阵:  
 $\forall \mathbf{b} \in \mathbb{R}^m$ , 有唯一分解:

$$\mathbf{b} = \mathbf{b}_1 + \mathbf{b}_2 = P_A \mathbf{b} + P_{A^\perp} \mathbf{b}.$$

其中,  $\mathbf{b}_1 = P_A \mathbf{b} \in \mathcal{R}(A)$ ,  $\mathbf{b}_1^\mathrm{T} \mathbf{b}_2 = 0$ .



$$\|\mathbf{b} - P_A \mathbf{b}\| = \min_{\tilde{\mathbf{b}} \in \mathcal{R}(A)} \|\mathbf{b} - \tilde{\mathbf{b}}\|.$$

$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{b} - A\mathbf{x}\| \iff A\mathbf{x} = P_A\mathbf{b}.$  总是有解，但不一定唯一。

► 正则化方法。

$\mathbf{x}$  是最小二乘解。  $\iff A^T A\mathbf{x} = A^T \mathbf{b}.$  (解可能不唯一)

►  $QR$  分解。

•  $\text{rank}(A) = n$ , 即  $A$  列满秩时,

$\mathbf{x}$  是最小二乘解。  $\iff R_1 \mathbf{x} = Q_1^T \mathbf{b}.$

•  $\text{rank}(A) = r < n$ :

$P_A = U_r U_r^T \Rightarrow U_r \Sigma_r V_r^T \mathbf{x} = U_r U_r^T \mathbf{b}.$  (解不唯一)

最小二乘解中长度最小的解:  $\mathbf{x} = V_r \Sigma_r^{-1} U_r^T \mathbf{b} = A^+ \mathbf{b}.$

存在对应的可逆矩阵。

❶ 左相抵:  $A = XB = PLU$ .

❷ 相抵:  $A = XBY = XD_rY$ .

❸ 相似:  $A = XBX^{-1} = XTX^{-1} = XJX^{-1} \in \mathbb{C}^{n \times n}$ .  $J$  为Jordan 块构成的对角分块矩阵。

❹ 正交相似:  $A = QBQ^T$ , 其中  $Q$  正交. 实对称  $A = Q\Lambda Q^T$ .

❺ 合同:  $A = XTX^T = XJX^T$ . Sylvester 惯性定律。

❻ 对应的标准形和不变量。

给定非零  $\mathbf{x}$ , 其关于方阵  $A$  的Rayleigh 商为  $\frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$ .

实对称  $A$ :

- 做特征值排序  $\lambda_1 \geq \dots \geq \lambda_n$ ,
- 取其正交单位特征向量组  $\mathbf{q}_1, \dots, \mathbf{q}_n$ . 有:

$$\lambda_1 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}; \quad \lambda_i = \max_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x} \perp \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_{i-1})}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \quad \text{for } i = 2, \dots, n.$$

$$\lambda_n = \min_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}; \quad \lambda_i = \min_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x} \in \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_{i-1})}} \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \quad \text{for } i = 1, \dots, n-1.$$



1

$$\begin{aligned}\|A\| &= \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| \\ &= \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_{\max}(A A^T)} \\ &= \sigma_{\max}(A) = \sigma_1.\end{aligned}$$

2 低秩逼近。

$$\|A - A_k\| = \min_{\text{rank}(B) \leq k} \|A - B\| = \sigma_{k+1},$$

其中  $k < r$ ,  $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$ .