

1.(a) 关于矩阵正定.

我们选择考察 $A = \begin{bmatrix} 1 & 2 & 2 \\ 2 & d & 4 \\ 2 & 4 & 5 \end{bmatrix}$ 的所有顺序主子式.

$$\det(A_1) = \det([1]) = 1 > 0.$$

$$\det(A_2) = \det\left(\begin{bmatrix} 1 & 2 \\ 2 & d \end{bmatrix}\right) = d - 4 > 0. \iff d > 4.$$

$$\begin{aligned} \det(A_3=A) &= \begin{vmatrix} 1 & 2 & 2 \\ 2 & d & 4 \\ 2 & 4 & 5 \end{vmatrix} \xrightarrow{R_3-R_2} \begin{vmatrix} 1 & 2 & 2 \\ 2 & d & 4 \\ 0 & 4-d & 1 \end{vmatrix} = 1 \begin{vmatrix} d & 4 \\ 4-d & 1 \end{vmatrix} - 2 \begin{vmatrix} 2 & 2 \\ 4-d & 1 \end{vmatrix} \\ &= d - 4(4-d) - 2[2 \cdot 2(4-d)] = d - 4(4-d) - 4 + 4(4-d) = d - 4 > 0 \\ &\iff d > 4. \end{aligned}$$

综上所述, A 正定 $\iff d > 4$.

(b) 关于矩阵半正定.

我们计算 \forall 给定 $\vec{x} \in \mathbb{R}^3$, $\vec{x}^T A \vec{x} = \sum_{i=1}^3 \sum_{j=1}^3 a_{ij} x_i x_j$, 所以

$$\vec{x}^T A \vec{x} = d x_2^2 + x_1^2 + 5 x_3^2 + 4 x_1 x_2 + 4 x_1 x_3 + 8 x_2 x_3.$$

分两种情形:

(i) $x_2 = 0$.

\forall 非零 \vec{x} , 则有 $\vec{x}^T A \vec{x} = x_1^2 + 5 x_3^2 + 4 x_1 x_3 = (x_1 + 2 x_3)^2 + x_3^2 > 0$ 总是成立的.

所以对 d 无任何取值限制.

(ii) $x_2 \neq 0$.

由前一部分 (a) 的结论可知, 仍有 $\vec{x}^T A \vec{x} > 0$ for $d > 4$, $\forall \vec{x} \in \mathbb{R}^3$ with $x_2 \neq 0$. 所以我们只需考虑 $d = 4$ 和 $d < 4$ 的情形.

固定 \vec{x} , $\vec{x}^T A \vec{x}$ 是关于 d 的一次函数, 又因为 $x_2 \neq 0$, 所以 $\vec{x}^T A \vec{x}$ 关于 d 严格单调递增. 不妨记函数 $f_{\vec{x}}(d) = \vec{x}^T A \vec{x}$, ie

$$f_{\vec{x}}(d) = x_2^2 d + x_1^2 + 5 x_3^2 + 4 x_1 x_2 + 4 x_1 x_3 + 8 x_2 x_3.$$

所以有 $f_{\vec{x}}(d) > 0$ for any $d > 4$, $\forall \vec{x} \in \mathbb{R}^3$ with $x_2 \neq 0$.

考察向量 $\vec{x}^* = [1 \ -\frac{1}{2} \ 0]^T$, 则有

$$f_{\vec{x}^*}(4) = 4 x_2^2 + x_1^2 + 4 x_1 x_2 = 4 \cdot \frac{1}{4} + 1 + 4 \cdot 1 \cdot (-\frac{1}{2}) = 0.$$

由 $f_{\vec{x}^*}(d)$ 关于 d 的严格递增和连续性可知

$$f_{\vec{x}^*}(d) < 0 \text{ for any } d < 4.$$

又由 $f_{\vec{x}}(d) = \vec{x}^T A \vec{x}$ 的定义可知,

$\vec{x}^T A \vec{x} \geq 0$ for any $d \geq 4$, any $\vec{x} \in \mathbb{R}^3$ with $x_2 \neq 0$,
且存在非零向量 $\vec{x}^* \in \mathbb{R}^3$, 使得

$$\vec{x}^{*T} A \vec{x}^* < 0 \quad \text{for any } d < 4.$$

ie. 矩阵 A with $d < 4$ 是不定矩阵, 而矩阵 A 半正定 $\Leftrightarrow d \geq 4$. \square

2. 因为 A 实对称, 所以 A 有谱分解 $A = Q \Lambda Q^T$, 其中 Q 是正交矩阵, Λ 是由 A 的特征值 (记重数) 构成的对角矩阵, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$.

$$tI_n + A = tI_n + Q \Lambda Q^T = Q (tI_n) Q^T + Q \Lambda Q^T$$

数量矩阵与任何矩阵交换

$$= Q (tI_n + \Lambda) Q^T =: Q D Q^T.$$

取 $t > \max_{1 \leq i \leq n} (-\lambda_i)$, 则 $tI_n + \Lambda = D = \text{diag}(d_1, \dots, d_n)$ where

for $1 \leq j \leq n$, $d_j = t + \lambda_j > \max_{1 \leq i \leq n} (-\lambda_i) + \lambda_j > -\lambda_j + \lambda_j = 0$.

所以 D 是对角元素严格大于 0 的对角矩阵, 从而是正定的.

而 $tI_n + A$ 与 D 正交相似, 所以也正定. \square

3. 使用 A 的谱分解: $A = Q \Lambda Q^T$, 其中 Q 是正交矩阵, Λ 是由 A 的特征值 (记重数) 构成的对角矩阵, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$.

$$\forall \vec{x} \in \mathbb{R}^n, \text{ 有 } \vec{x}^T A \vec{x} = \vec{x}^T Q \Lambda Q^T \vec{x} = \vec{y}^T \Lambda \vec{y}, \text{ 其中 } \vec{y} = Q^T \vec{x}$$

$$= \sum_{i=1}^n \lambda_i y_i^2 \leq \lambda_{\max} \sum_{i=1}^n y_i^2 = \lambda_{\max} \|\vec{y}\|^2 = \lambda_{\max} \|\vec{x}\|^2,$$

正交矩阵保距

$$\text{其中 } \lambda_{\max} = \max_{1 \leq j \leq n} \lambda_j.$$

取 $C = \max\{\lambda_{\max}, 1\}$, 则有 $\vec{x}^T A \vec{x} \leq C \|\vec{x}\|^2 = C \vec{x}^T \vec{x} \quad \forall \vec{x} \in \mathbb{R}^n$.

保证 C 为正实数.

4. 可结合习题中关于 A 矩阵半正定的等价结论.

A 半正定 $\Leftrightarrow A$ 的所有主子式都非负.

$$\text{取 } A = \begin{bmatrix} 0 & 2 \\ -1 & 0 \end{bmatrix}. \quad \forall \vec{x} \in \mathbb{R}^2, \text{ 计算 } \vec{x}^T A \vec{x} = -x_1^2 + 2x_1x_2 + 0x_2^2$$

$$= -x_1^2 + 2x_1x_2$$

$$= x_1(2x_2 - x_1).$$

不妨取 $x_1 = 4, x_2 = 1$, 则有 $\vec{x}^T A \vec{x} = 4 \cdot (2 \cdot 1 - 4) = -8 < 0$.

计算 $\vec{x}^T A \vec{x} = 2x_1x_2 - x_2x_1 = x_1x_2$, 会随着 \vec{x} 的变化而变号, 所以 A 不是半正定矩阵. 另一方面, 考察 A 的顺序主子式:

$$\det(A_1) = \det([0]) = 0 \geq 0$$

$$\det(A_2=A) = \begin{vmatrix} 0 & 2 \\ -1 & 0 \end{vmatrix} = 0 - (-1) \cdot 2 = 2 > 0$$

所以 A 的顺序主子式都非负. 综上所述,

A 半定 $\nleftrightarrow A$ 的所有顺序主子式都非负. 只有 " \Rightarrow " 成立.

$$5. \forall \text{非零 } \vec{x} \in \mathbb{R}^n, \vec{x}^T A \vec{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j = \sum_{i=1}^n \left(\underbrace{a_{ii} x_i^2}_{\geq 0} + \sum_{j \neq i} a_{ij} x_i x_j \right)$$

$$> \sum_{i=1}^n \left(\sum_{j \neq i} |a_{ij}| x_i^2 + \sum_{j \neq i} a_{ij} x_i x_j \right)$$



x_i 不全为零, 所以 " $>$ " 总是成立的.

$$= \sum_{i=1}^n \sum_{j \neq i} (|a_{ij}| x_i^2 + a_{ij} x_i x_j) =: I$$

讨论 I , 我们变换指标 i 和 j :

$$I = \sum_{j=1}^n \sum_{i \neq j} (|a_{ji}| x_j^2 + a_{ji} x_j x_i) \quad \text{对换 } i \text{ 和 } j$$

$$\stackrel{\text{交换求和顺序}}{=} \sum_{i=1}^n \sum_{j \neq i} (|a_{ji}| x_j^2 + a_{ji} x_j x_i)$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i} (|a_{ij}| x_i^2 + a_{ij} x_i x_j + |a_{ji}| x_j^2 + a_{ji} x_j x_i)$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i} (|a_{ij}| (x_i^2 + x_j^2) + 2 a_{ij} x_i x_j) \quad \text{因为 } A \text{ 对称}$$

$$\geq \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i} (|a_{ij}| (x_i^2 + x_j^2) - 2 |a_{ij}| \cdot |x_i| \cdot |x_j|)$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i} |a_{ij}| (x_i^2 + x_j^2 - 2 |x_i| |x_j|)$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i} |a_{ij}| (|x_i| - |x_j|)^2 \geq 0$$

所以 \forall 非零 $\vec{x} \in \mathbb{R}^n$, 有 $\vec{x}^T A \vec{x} > 0$, i.e. A 正定. □

Remark: 数学归纳法应该也可以给出一个证明.

6. 因为 $A^T = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} = -A$, 所以 A 反对称, 则有 $\vec{x}^T A \vec{x} = 0 \quad \forall \vec{x} \in \mathbb{R}^n$.

所以 $\max_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}} = 0$. □

7. 利用 $\vec{x}^T A \vec{x} = \vec{x}^T A^S \vec{x}$, 其中 $A^S = \frac{A+A^T}{2} = \frac{1}{2} \left(\begin{bmatrix} 2 & 10 \\ -2 & -2 \end{bmatrix} + \begin{bmatrix} 2 & -2 \\ 10 & -2 \end{bmatrix} \right)$

$$= \frac{1}{2} \begin{bmatrix} 4 & 8 \\ 8 & -4 \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ 4 & -2 \end{bmatrix}$$

因为 A^S 是对称矩阵, 有 $\lambda_1 = \max_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A^S \vec{x}}{\vec{x}^T \vec{x}}$, 其中 λ_1 是 A^S 的最大特征值.

计算 A^S 的特征多项式 $P_{A^S}(\lambda) = \begin{vmatrix} \lambda-2 & -4 \\ -4 & \lambda+2 \end{vmatrix} = (\lambda-2)(\lambda+2) - 16 = \lambda^2 - 4 - 16 = \lambda^2 - 20$.

由 $P_{A^S}(\lambda) = 0$ 可知 $\lambda = \pm \sqrt{20} = \pm 2\sqrt{5}$.

所以 $\max_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}} = \max_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A^S \vec{x}}{\vec{x}^T \vec{x}} = 2\sqrt{5}$. □

8. (a) $A = \begin{bmatrix} 3 & 5 & 0 \end{bmatrix} = U \Sigma V^T$, 其中 U 是 1 阶正交矩阵, 则必为 $U = [1]$,
 $\Sigma = [\Sigma, 0 \ 0] = [\sigma, 0 \ 0]$, V 是 3 阶正交矩阵.

因为 A 较简单, 可直接求解 $V = [\vec{v}_1 \ \vec{v}_2 \ \vec{v}_3]$.

由 A 的简化 SVD 可知 $A = U \Sigma V_1^T$ 可知

$$\begin{bmatrix} 3 & 5 & 0 \end{bmatrix} = [1] [\sigma_1] \vec{v}_1^T = \sigma_1 \vec{v}_1^T$$

因为 \vec{v}_1 是单位向量, 所以 $\sigma_1 = \left\| \begin{bmatrix} 3 \\ 5 \\ 0 \end{bmatrix} \right\| = \sqrt{3^2 + 5^2 + 0^2} = \sqrt{34}$.

从而有 $\vec{v}_1^T = \frac{1}{\sigma_1} \begin{bmatrix} 3 & 5 & 0 \end{bmatrix} = \frac{1}{\sqrt{34}} \begin{bmatrix} 3 & 5 & 0 \end{bmatrix}$.

由 \vec{v}_1 扩充出 \vec{v}_2 和 \vec{v}_3 , 从而得到 V . 因为现在只有一个向量, 且 \vec{v}_1 的第 3 个元素为 0.
 由经验可选择 $\vec{v}_2^T = \frac{1}{\sqrt{34}} \begin{bmatrix} -5 & 3 & 0 \end{bmatrix}$, 和 $\vec{v}_3^T = \vec{e}_3^T$.

所以 $V = \begin{bmatrix} \frac{3}{\sqrt{34}} & -\frac{5}{\sqrt{34}} & 0 \\ \frac{5}{\sqrt{34}} & \frac{3}{\sqrt{34}} & 0 \\ 0 & 0 & 1 \end{bmatrix}$, 和 $A = U \Sigma V^T$. □

(b) $B = AA^T = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & -1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$.

$$p_B(\lambda) = \begin{vmatrix} \lambda-2 & -1 \\ -1 & \lambda-2 \end{vmatrix} = (\lambda-2)^2 - 1. \text{ 由 } p_B(\lambda)=0 \text{ 可得 } \lambda-2=\pm 1 \Rightarrow \lambda_1=3, \lambda_2=1.$$

$$\lambda_1=3: \lambda_1 I_2 - B = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}, \text{ 可取特征向量 } \vec{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \vec{u}_1 = \frac{\vec{x}_1}{\|\vec{x}_1\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

$$\lambda_2=1: \lambda_2 I_2 - B = \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix}, \text{ 可取特征向量 } \vec{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \vec{u}_2 = \frac{\vec{x}_2}{\|\vec{x}_2\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

$$\text{所以 } U = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \Sigma = [\Sigma_2 \quad \vec{0}] = \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

由A的简化SVD: $A = U \Sigma_2 V_1^T$ 可知 $V_1^T = \Sigma_2^{-1} U^T A$, 所以有

$$\begin{aligned} [\vec{v}_1 \quad \vec{v}_2]^T &= \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & -1 \\ 1 & 0 & 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{3}} & -\frac{1}{\sqrt{3}} \\ 1 & 0 & 1 \end{bmatrix}. \end{aligned}$$

我们需要用 \vec{v}_1 和 \vec{v}_2 扩充出 \vec{v}_3 . 事实上, \vec{v}_1 和 \vec{v}_2 有一定特点, 容易验证:

$$\text{向量 } \vec{x}_3^T = [-1 \quad 1 \quad 1] \text{ 与 } \vec{v}_1 \text{ 和 } \vec{v}_2 \text{ 都正交. 可取 } \vec{v}_3 = \frac{\vec{x}_3}{\|\vec{x}_3\|} = \frac{1}{\sqrt{3}} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}.$$

$$\text{所以 } V = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{bmatrix}, \text{ 和}$$

$$A = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{bmatrix}^T \quad \square$$

(c) 记 $B = \begin{bmatrix} A & 0 \\ 0 & 0 \end{bmatrix}$, ~~三个分块零矩阵~~ 可匹配成任意大小. 不妨设 $\begin{cases} B \in \mathbb{R}^{p \times q} \\ A \in \mathbb{R}^{m \times n} \end{cases}$.

$$\text{记 } B \text{ 的 SVD 为 } B = \tilde{U} \tilde{\Sigma} \tilde{V}^T = \begin{bmatrix} \tilde{u}_1 & \tilde{u}_2 \end{bmatrix} \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \tilde{v}_1^T \\ \tilde{v}_2^T \end{bmatrix},$$

B 与 $\tilde{\Sigma}$ 相抵, 可引入下列分块:

$$\text{所以 } B = \tilde{U}_1 \tilde{\Sigma} \tilde{V}_1^T = \begin{bmatrix} A & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} U & \tilde{U} \\ \tilde{V} & \tilde{V} \end{bmatrix} \tilde{\Sigma}$$

$$B = \begin{bmatrix} \tilde{u}_{11} & \tilde{u}_{12} \\ \tilde{u}_{21} & \tilde{u}_{22} \end{bmatrix} \begin{bmatrix} \Sigma_{11} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \tilde{v}_{11} & \tilde{v}_{12} \\ \tilde{v}_{21} & \tilde{v}_{22} \end{bmatrix}^T, \text{ 其中 } \Sigma_{11} \in \mathbb{R}^{m \times n}, \tilde{U} \text{ 和 } \tilde{V}$$

作对应的分块, 则有

$$B = \begin{bmatrix} \tilde{U}_{11} \Sigma_{11} & 0 \\ \tilde{U}_{21} \Sigma_{11} & 0 \end{bmatrix} \begin{bmatrix} \tilde{V}_{11}^T & \tilde{V}_{21}^T \\ \tilde{V}_{12}^T & \tilde{V}_{22}^T \end{bmatrix} = \begin{bmatrix} \tilde{U}_{11} \Sigma_{11} \tilde{V}_{11}^T & \tilde{U}_{11} \Sigma_{11} \tilde{V}_{21}^T \\ \tilde{U}_{21} \Sigma_{11} \tilde{V}_{11}^T & \tilde{U}_{21} \Sigma_{11} \tilde{V}_{21}^T \end{bmatrix} = \begin{bmatrix} A & 0 \\ 0 & 0 \end{bmatrix}.$$

所以应有 $\tilde{U}_{11} \Sigma_{11} \tilde{V}_{11}^T = A = U \Sigma V^T$, $\tilde{U}_{11} \Sigma_{11} \tilde{V}_{21}^T = 0$, $\tilde{U}_{21} \Sigma_{11} \tilde{V}_{11}^T = 0$, $\tilde{U}_{21} \Sigma_{11} \tilde{V}_{21}^T = 0$.

我们可以选取 $\tilde{U}_{11} = U$, $\Sigma_{11} = \Sigma$, $\tilde{V}_{11} = V$, $\tilde{U}_{12} = \tilde{U}_{21} = 0$, $\tilde{V}_{12} = 0$, $\tilde{V}_{21} = 0$.

$$\text{从而有 } \tilde{U} = \begin{bmatrix} U & 0 \\ 0 & \tilde{U}_{22} \end{bmatrix}, \quad \tilde{\Sigma} = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}, \quad \tilde{V} = \begin{bmatrix} V & 0 \\ 0 & \tilde{V}_{22} \end{bmatrix}.$$

注意到 $\tilde{U}_{22} \in \mathbb{R}^{(p-m) \times (p-m)}$, $\tilde{V}_{22} \in \mathbb{R}^{(q-n) \times (q-n)}$, 不妨取 $\tilde{U}_{22} = I_{p-m}$, $\tilde{V}_{22} = I_{q-n}$.

$$\text{则有 } B = \begin{bmatrix} U & 0 \\ 0 & I_{p-m} \end{bmatrix} \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V & 0 \\ 0 & I_{q-n} \end{bmatrix}^T = \begin{bmatrix} U \Sigma V^T & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} A & 0 \\ 0 & 0 \end{bmatrix}. \quad \square$$

9. 不妨设 $A \in \mathbb{R}^{m \times n}$, 则 $B = \begin{bmatrix} 0 & A^T \\ A & 0 \end{bmatrix} \in \mathbb{R}^{(m+n) \times (m+n)}$.

$$\text{记 } A \text{ 的 SVD 为 } A = U \Sigma V^T = [\vec{u}_1 \dots \vec{u}_m] \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \vec{v}_1^T \\ \vdots \\ \vec{v}_n^T \end{bmatrix}.$$

取 \mathbb{R}^{m+n} 中的向量 $\vec{x}_i = \begin{bmatrix} \vec{v}_i \\ \vec{u}_i \end{bmatrix}$ for $1 \leq i \leq r$. 有

$$B \vec{x}_i = \begin{bmatrix} 0 & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \vec{v}_i \\ \vec{u}_i \end{bmatrix} = \begin{bmatrix} A^T \vec{u}_i \\ A \vec{v}_i \end{bmatrix} = \begin{bmatrix} \sigma_i \vec{v}_i \\ \sigma_i \vec{u}_i \end{bmatrix} = \sigma_i \begin{bmatrix} \vec{v}_i \\ \vec{u}_i \end{bmatrix} = \sigma_i \vec{x}_i.$$

所以 (σ_i, \vec{x}_i) for $1 \leq i \leq r$ 是 B 的特征对.

考虑向量 $\vec{y}_i = \begin{bmatrix} -\vec{v}_i \\ \vec{u}_i \end{bmatrix}$ for $1 \leq i \leq r$, 则有

$$B \vec{y}_i = \begin{bmatrix} 0 & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} -\vec{v}_i \\ \vec{u}_i \end{bmatrix} = \begin{bmatrix} A^T \vec{u}_i \\ -A \vec{v}_i \end{bmatrix} = \begin{bmatrix} \sigma_i \vec{v}_i \\ -\sigma_i \vec{u}_i \end{bmatrix} = -\sigma_i \begin{bmatrix} -\vec{v}_i \\ \vec{u}_i \end{bmatrix} = -\sigma_i \vec{y}_i.$$

所以 $(-\sigma_i, \vec{y}_i)$ for $1 \leq i \leq r$ 也是 B 的特征对.

考虑向量 $\vec{z}_i = \begin{bmatrix} \vec{v}_i \\ \vec{0}_m \end{bmatrix}$ for $r+1 \leq i \leq n$, 则有

$$B \vec{z}_i = \begin{bmatrix} 0 & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \vec{v}_i \\ \vec{0}_m \end{bmatrix} = \begin{bmatrix} \vec{0}_n \\ A \vec{v}_i \end{bmatrix} = \begin{bmatrix} \vec{0}_n \\ \vec{0}_m \end{bmatrix} = 0 \cdot \begin{bmatrix} \vec{v}_i \\ \vec{0}_m \end{bmatrix}.$$

所以 $(0, \vec{z}_i)$ for $r+1 \leq i \leq n$ 是 B 的特征对.

考虑向量 $\vec{w}_i = \begin{bmatrix} \vec{0}_n \\ \vec{u}_i \end{bmatrix}$ for $r+1 \leq i \leq m$, 则有

$$B\vec{x} = \begin{bmatrix} 0 & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \vec{0}_n \\ \vec{u}_i \end{bmatrix} = \begin{bmatrix} A^T \vec{u}_i \\ \vec{0}_m \end{bmatrix} = \begin{bmatrix} \vec{0}_n \\ \vec{0}_m \end{bmatrix} = 0 \cdot \begin{bmatrix} \vec{0}_n \\ \vec{u}_i \end{bmatrix} = 0 \vec{x}_i.$$

所以 $(0, \vec{x}_i)$ for $r+1 \leq i \leq m$ 是 B 的特征对.

综上所述, 由 $\{\vec{u}_i\}_{i=1}^m$ 和 $\{\vec{v}_i\}_{i=1}^n$ 各自的线性无关性可知, 我们可得到可逆矩阵 $X = [\vec{x}_1 \cdots \vec{x}_r \vec{x}_{r+1} \cdots \vec{x}_m \vec{x}_{r+1} \cdots \vec{x}_n \vec{x}_{r+1} \cdots \vec{x}_m]$,

和对角矩阵 $\Lambda = \text{diag}(\sigma_1, \dots, \sigma_r, -\sigma_1, \dots, -\sigma_r, 0, \dots, 0)$, 从而有 B 的谱分解:

$$B = X\Lambda X^{-1}.$$

④

10.(a) A 是下三角矩阵, 且对角元素均非零, 所以 A 可逆. 所以 $(AA^T)^{-1}$ 是有定义的.

因为 $\vec{w} \in A(C)$, 所以存在单位向量 \vec{v} , s.t. $A\vec{v} = \vec{w}$.

$$\text{计算 } \vec{w}^T (AA^T)^{-1} \vec{w} = (A\vec{v})^T A^{-T} (A^{-1} A) \vec{v} = \vec{v}^T (A^T A^{-1}) \vec{v} = \vec{v}^T \vec{v} = \|\vec{v}\|^2 = 1.$$

$$(b) B = A^T A = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix}^T \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix}.$$

$$p_B(\lambda) = \begin{vmatrix} \lambda - 2 & 1 \\ 1 & \lambda - 1 \end{vmatrix} = (\lambda - 2)(\lambda - 1) - 1 = \lambda^2 - 3\lambda + 2 - 1 = \lambda^2 - 3\lambda + 1.$$

$$\text{由 } p_B(\lambda) = 0 \text{ 可知 } \lambda = \frac{3 \pm \sqrt{3^2 - 4}}{2} = \frac{3 \pm \sqrt{5}}{2}.$$

$$\text{所以 } \sigma_1 = \sqrt{\frac{3 + \sqrt{5}}{2}}, \quad \sigma_2 = \sqrt{\frac{3 - \sqrt{5}}{2}}.$$


我不想算了. 引以文字说明求解 SVD 的过程, 或使用数学软件得到一个结果. 这个计算结果其实和 (c) 的讨论无关, 但可以使用画图软件给出一个视觉化的结果.

(c). V^T 也是二阶正交矩阵, 对左旋转或反射. 而 C 是一个圆, 它代表的从原点出发的向量, 无论进行任何旋转或反射, 都还在这个圆上. 所以



$$V^T(C) = C.$$

$$\text{从而有 } \Sigma V^T(C) = \Sigma(C) = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} (C), \text{ 且 } \sigma_1 \neq \sigma_2.$$

对 C 上的向量, 分别伸缩了 x 坐标和 y 坐标, 从而得到一个椭圆. 由于 $\sigma_1 > \sigma_2$, 应有一个横着的椭圆, 记为 E .



所以 $U \Sigma V^T(C) = U(E)$, U 是正交矩阵, 只代表旋转或反射, 所以椭圆 E 被绕着原点转动. 转动的角度由 U 的具体取值决定.



11. 用微积分知识证明 $\lim_{x,y \rightarrow 0} \frac{4x^2+2xy+4y^2}{x^2+y^2}$ 不存在.

我们只考虑非零向量 $\vec{x} = \begin{bmatrix} x \\ y \end{bmatrix}$. 则有

$$4x^2+2xy+4y^2 = \vec{x}^T A \vec{x} \quad \text{with} \quad A = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix},$$

$$\text{另一方面 } x^2+y^2 = \vec{x}^T \vec{x}.$$

$$\text{所以 } \max_{x,y \text{ 不同时为零}} \frac{4x^2+2xy+4y^2}{x^2+y^2} = \max_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}} = \lambda_{\max}(A),$$

$$\min_{x,y \text{ 不同时为零}} \frac{4x^2+2xy+4y^2}{x^2+y^2} = \min_{\vec{x} \neq \vec{0}} \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}} = \lambda_{\min}(A).$$

$$\text{而 } P_A(\lambda) = \begin{vmatrix} \lambda-4 & 1 \\ -1 & \lambda-4 \end{vmatrix} = (\lambda-4)^2 - 1 = 0 \quad \exists \text{ 得到 } \lambda-4 = \pm 1, \quad \lambda_1=5, \lambda_2=3.$$

$$\text{所以 } \lambda_{\max}(A)=5, \quad \lambda_{\min}(A)=3.$$

所以 x, y 不同时为零时, $\frac{4x^2+2xy+4y^2}{x^2+y^2}$ 的最大值和最小值分别为 5 和 3.